


个人的感觉是从 Claude Sonnet 4.5 开始，LLM 搭配 AI Agent 真的能干活了。随便选一款 LLM 就行，最划算的还是deepseek flash。

使用 Deepseek


我比较熟悉VS Code，因此 GitHub Copilot 用得也最多。它的优点是可以直接在IDE中选择让AI读取的代码片段，而不是让 AI 去找。使用方法如下：

1. 安装 Deepseek V4 for Copilot Chat



2. 充钱，设置 API key

3. 推荐设置 autopilot 模式



安全问题

1. 创建单独的帐号，只允许在自己的文件夹下运行。
2. 自部署模型。Qwen3.8 27b 这个模型已经能干大部分工作了。我曾试过在我们的服务器上部署，两张 4090 刚好够用。单张4090只能运行，但没法达到 25 万token的上下文，实际干活用不了。所以买机器非常不划算（买新机器的话不用买内存，之前那台服务器在内存价格低点屯了384G，可以拆一半下来给新机器用。以前1000条，现在6000一条）

OpenAI 和 Claude

比Deekseek强。API非常贵，推荐订阅使用，只能用他们自己的软件。在中国使用 Claude 的话，帐号有一定几率被封。OpenAI 可以通过VPN使用。